Estatística experimental

Davi Vitti

2023-09-10

Contents

Chapter 1

Introdução

Chapter 2

Relembrando a Estatística geral

2.1 Medidas de posição

2.2 Medidas de dispersão

Média

Variância

Desvio-padrão

Coeficiente de Variação

2.2.1 Aplicação no R studio

2.3 Exercicíos

Chapter 3

Planejamento e princípios básicos

3.1 Aplicação no R studio

3.2 Exercicíos

```
knitr::opts_chunk$set(comment = "", prompt = TRUE)
```

Chapter 4

Delineamento inteiramente casualizado

O delineamento inteiramente casualizado (DIC) é o mais simples dos delineamentos, pois considera apenas dois dos princípios básicos da experimentação: a repetição e a casualização. Neste, os tratamentos são aleatoriamente atribuídos ao material experimental, sem o esforço de se restringir os tratamentos a alguma porção de área, material ou espaço. Ainda como característica, como não há uso do controle local o número de repetições por tratamento pode variar.É geralmente utilizado quando a variação do material experimental é relativamente pequena, o que geralmente ocorre em laboratórios e casas de vegetação. Como vantagens de sua utilização temos que é um experimento de fácil planejamento e que permite o número máximo de graus de liberdade do Resíduo. Em termos de análise é a mais simples quando comparado aos demais delineamentos experimentais e não apresentará confundimento caso os tratamentos tenham números diferentes de repetições. Entretanto, como desvantagens temos que o delineamento inteiramente casualizado é adequado aos experimentos com baixo número de tratamentos e material experimental homogêneo, o que nem sempre se consegue. Quando um grande número de tratamentos é utilizado, há um crescimento no material experimental, que pode inflacionar a variação experimental. Nesses casos o Delineamento Inteiramente Casualizado não é indicado.

Obtendo um croqui para um DIC

Para obtermos um croqui para um experimento com I tratamentos em um DIC, sendo o iésimo tratamento repetido ni vezes e o número total de parcelas $n = \sum_{i=1}^{I} n_i$

(i) Enumerar as parcelas 1, 2, . . . , n
(ii) Criar o delineamento sistemático, ou seja, alocar o tratamento 1 às parcelas 1, 2, . . . , n1 alocar o tratamento 2 às parcelas n1 + 1, n1 + 2, . . .

, n1 + n2 e assim até as repetições do tratamento I.

(iii) Escolha uma permutação de 1, 2, . . . , n e aplique ao delineamento.

Exemplo

Suponha que desejamos comparar a produtividade de três variedades de soja, com três, quatro e três repetições respectivamente. O plano de casualização para o delineamento sistemático é dado por:

Ordem Padrão	1	2	3	4	5	6	7	8	9	10
Variedade	A	A	A	B	B	B	B	C	C	C

Uma permutação:

Parcelas	7	1	8	10	3	2	4	6	9	5
Ordem Padrão	1	2	3	4	5	6	7	8	9	10

E o plano de casualização é dado por:

Parcela	1	2	3	4	5	6	7	8	9	10
Variedade	B	A	C	C	A	A	B	B	C	A

Análise dos dados

Entende-se como objetivo inicial de um experimento a verificação dos efeitos de tratamentos. Aqui será utilizada a Análise de Variância (ANOVA) para tal verificação. A ANOVA é utilizada na comparação de médias de dois ou mais tratamentos ou teste para a variância dos tratamentos, por meio do teste F (Fisher). Trata-se de uma extensão do teste t de Student, permitindo que o pesquisador compare qualquer número de médias, quando o efeito de tratamentos é fixo.

Modelo estatistico

O modelo estatístico para a análise dos dados oriundos de um DIC com um único fator de tratamentos é dado pela Equação 1.

$y_{ij} = \mu + \tau_i + e_{ij} = \mu_i + e_{ij}$

em que:

- y_{ij} é o valor observado na jésima repetição do iésimo tratamento, com:
  - i = 1, . . . , I e

  - j = 1, . . . , ni

- μ é uma constante inerente a todas as observações, geralmente a média geral,
- τ_i é o efeito do iésimo tratamento,
- eij é o erro experimental, tal que $Eijiid \sim N(0, \sigma^2)$.

Realizando-se a ANOVA, testamos as hipóteses:

$H0 : \tau 1 = \tau 2 = ... = \tau I = 0$

$H1 = Ha$: $\tau i6 = 0$ para algum i.

Havendo uma reparametrização do modelo apresentado na Equação 1, tal que $\mu + \tau_i = \alpha i$ em que αi é a média do iésimo tratamento, e:

$yij = \alpha i + eij$, (2)

as hipóteses de interesse passam a ser

$H0 : \alpha 1 = \alpha 2 = ... = \alpha I = \mu$

$H1 = Ha$: pelo um contraste de médias difere de zero.

Neste momento assumiremos que as pressuposições de normalidade e independência dos erros, bem a homogeneidade de suas variâncias garantidas. Assim, assumimos que eij corresponde a uma realização da variável Eij , tal que $Eijiid \sim N(0, \sigma^2)$ e os demais termos no modelo 1 são fixos. Cabe sailentar que o modelo citado é o modelo maximal, ou seja, aquele modelo mais complicado a ser considerado na análise. Desse modo, a esperança da variável aleatória Yij será

$E(Yij) = E(\mu + \tau_i + Eij) = \mu + \tau_i + 0 = \mu + \tau_i$

4.1 Aplicação no R studio

Planejamento e Croqui

```
> #' # Planejamento de um experimento
> set.seed(1234)
> sample(rep(c("A", "B", "C", "D"), 5))
```

```
 [1] "D" "A" "D" "C" "A" "C" "B" "D" "B" "C" "B" "B" "C" "D" "A" "D" "A" "A" "B"
[20] "C"
```

```
> #' ## Usando a biblioteca agricolae
>
> # Instalando
> # install.packages("agricolae",
> #                  dependencies = TRUE)
> # Habilitando as funções
> library(agricolae)
> trt = LETTERS[1:4]
> delineamento <- design.crd(trt,
+                            r = 5,
+                            serie = 0)
> delineamento
```

```
$parameters
$parameters$design
[1] "crd"

$parameters$trt
[1] "A" "B" "C" "D"

$parameters$r
[1] 5 5 5 5

$parameters$serie
[1] 0

$parameters$seed
[1] 1407173775

$parameters$kinds
[1] "Super-Duper"

$parameters[[7]]
[1] TRUE


$book
   plots r trt
1      1 1   C
2      2 1   B
3      3 1   D
4      4 2   D
5      5 2   B
6      6 2   C
7      7 3   B
```

```
8       8 3   D
9       9 4   B
10     10 4   D
11     11 5   B
12     12 1   A
13     13 2   A
14     14 3   C
15     15 3   A
16     16 4   A
17     17 5   D
18     18 4   C
19     19 5   A
20     20 5   C
```

```
> # Graficamente
>
> # install.packages("agricolaeplotr",
> #                  dependencies = TRUE)
> library(agricolaeplotr)
```

```
The legacy packages maptools, rgdal, and rgeos, underpinning the sp package,
which was just loaded, will retire in October 2023.
Please refer to R-spatial evolution reports for details, especially
https://r-spatial.org/r/2023/05/15/evolution4.html.
It may be desirable to make the sf package available;
package maintainers should consider adding sf to Suggests:.
The sp package is now running under evolution status 2
     (status 2 uses the sf package in place of rgdal)
```

```
Attaching package: 'agricolaeplotr'
```

```
The following object is masked from 'package:base':

    summary
```

```
> plot_design_crd(delineamento,
+                 ncols = 4,
+                 nrows = 5)
```

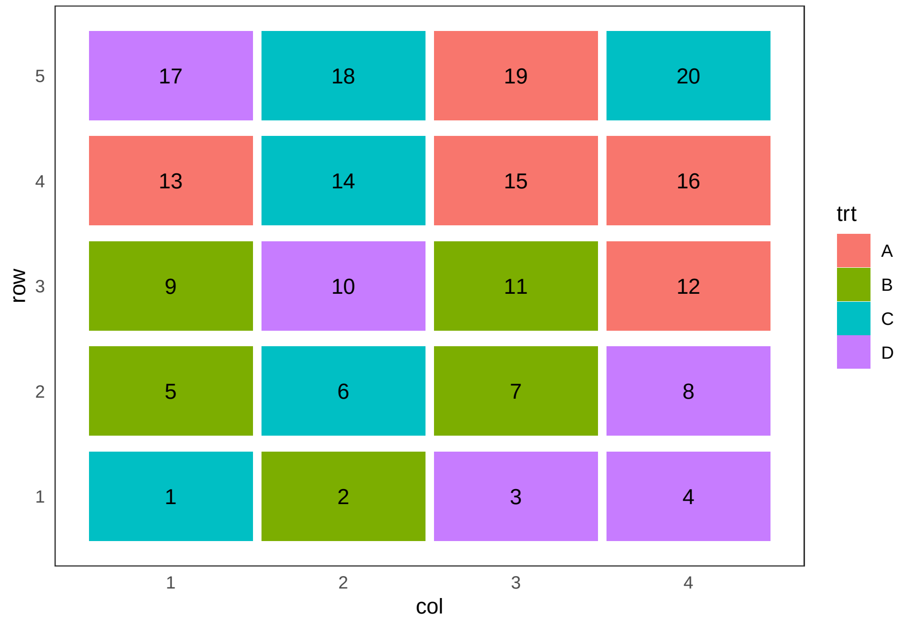


```
> # Para montar um croqui precisamos de um gride, definido por linhas e colunas
> delineamento$book$Linha <- rep(1:5, each = 4)
> delineamento$book$Coluna <- rep(1:4, times = 5)
>
> delineamento$book
```

```
   plots r trt Linha Coluna
1      1 1   C     1      1
2      2 1   B     1      2
3      3 1   D     1      3
4      4 2   D     1      4
5      5 2   B     2      1
6      6 2   C     2      2
7      7 3   B     2      3
8      8 3   D     2      4
9      9 4   B     3      1
10    10 4   D     3      2
11    11 5   B     3      3
12    12 1   A     3      4
13    13 2   A     4      1
14    14 3   C     4      2
15    15 3   A     4      3
16    16 4   A     4      4
17    17 5   D     5      1
```

```
18     18 4   C     5      2
19     19 5   A     5      3
20     20 5   C     5      4
```

Importando dados de excel .xlsx

```
> #Deve-se importar os arquivos .xlsx para o Rstudio
> library(readxl)
> dados1 <- read_xlsx("dados/aula2.2.xlsx")
>
> knitr::kable(dados1)
```

trat	y
A	25
A	26
A	20
A	23
A	21
B	31
B	25
B	28
B	27
B	24
C	22
C	26
C	28
C	25
C	29
D	33
D	29
D	31
D	34
D	28

Análise descritiva dos dados

```
> library(ggplot2)
> ggplot(dados1,
+        aes(x = trat,
+            y = y)) +
+   geom_point() +
+   geom_point(stat = "summary",
+              fun = mean,
+              col = "red") +
+   annotate("point",
```

```
+             x = dados1$trat,
+             y = 26.75,
+             colour = "blue") +
+   xlab("tratamentos") +
+   ylab("produtividade")
```

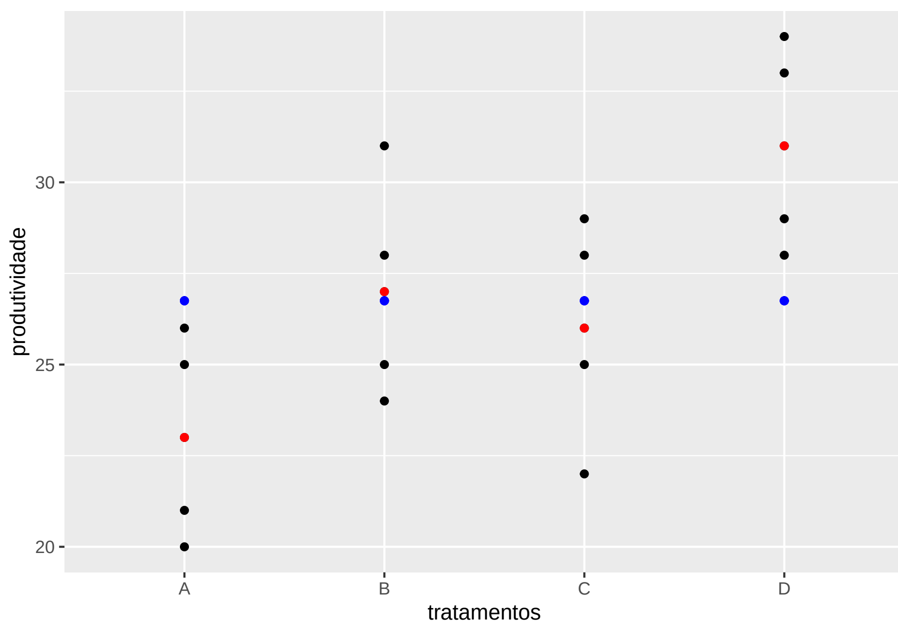


```
> ggplot(dados1,
+        aes(x = trat,
+            y = y)) +
+   geom_boxplot()
```

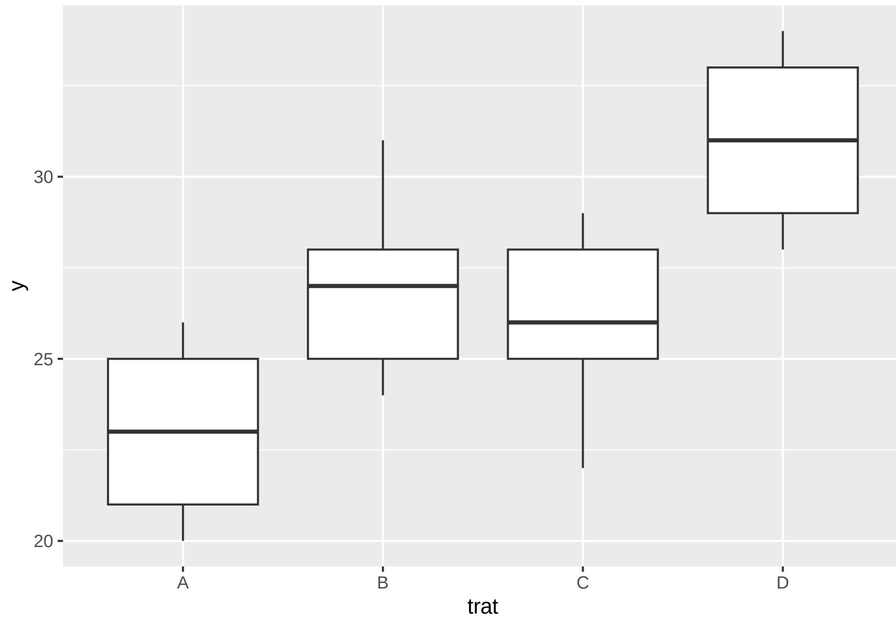


```
> #' ## Estatísticas descritivas
> n <- with(dados1, tapply(y,trat, length))
> soma <- with(dados1, tapply(y,trat,sum))
> media <- with(dados1, tapply(y,trat,mean))
> variancia <- with(dados1, tapply(y,trat,var))
> desv.padr <- with(dados1, tapply(y,trat,sd))
> dist.int <- with(dados1, tapply(y,trat,IQR))
```

```
> #' Criando uma função que calcula a amplitude
> f1 <- function(x) max(x)-min(x)
> amplitude <- with(dados1, tapply(y,trat,f1))
>
> resumo <- rbind(n, soma, media, variancia,
+                  desv.padr, amplitude,dist.int)
> rownames(resumo) <- c("n", "Soma", "Média",
+                       "Variância", "Desvio-padrão",
+                       "Amplitude", "Amplitude Interquartílica")
> round(resumo,3)
```

```
                               A       B       C      D
n                           5.00   5.000   5.000   5.00
Soma                      115.00 135.000 130.000 155.00
Média                      23.00  27.000  26.000  31.00
Variância                   6.50   7.500   7.500   6.50
```

```
Desvio-padrão                2.55   2.739   2.739   2.55
Amplitude                    6.00   7.000   7.000   6.00
Amplitude Interquartílica    4.00   3.000   3.000   4.00
```

Análise da variância (ANOVA)

```
> #' ## Análise de variância
> #'
> #' $H_0$: $\mu_1 = \mu_2 = \mu_3 = \mu_4$ *versus*
> #' $H_1:$ Pelo menos duas médias de tratamentos diferem entre si.
> #'
> modelo <- aov(y ~ trat, dados1)
> anova(modelo)
```

```
Analysis of Variance Table

Response: y
          Df Sum Sq Mean Sq F value   Pr(>F)
trat       3 163.75  54.583  7.7976 0.001976 **
Residuals 16 112.00   7.000
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

4.2 Exercicíos

1) Os dados apresentados na Tabela 1 são referentes ao peso de espigas de milho, em kg/10m², em cada parcela (10 m²). São apresentados os dados de 5 genótipos avaliados em um delineamento inteiramente casualizado (DIC) com 4 repetições.

Genótipos	I	II	III	IV
A	5,95	6,21	5,40	5,18
B	5,07	6,71	5,46	4,98
C	4,82	5,11	4,68	4,52
D	3,87	4,16	4,11	4,84
E	5,53	5,82	4,29	4,70

Considere os dados apresentados na Tabela. a) Faça um possível croqui de instalação para um novo experimento com o mesmo número de tratamentos (genótipos) e de repetições; b) Faça a análise exploratória dos dados de peso de espigas; c) Faça a análise de variância e interprete o resultado do teste F considerando o nível de significância 5%;

2) Em um experimento de competição de dez cultivares de arroz para avaliar a produtividade, instalado em um delineamento inteiramente casualizado, os resultados (parciais) para a ANOVA foram os seguintes:

Fonte	GL	SQ	QM	F Cal	F Tab
cultivar	x	17564523	x	9.31	2.39
Resíduo	x	x	x	x	x
Total	29	x	x	x	x

a) Complete o quadro da ANOVA

b) Com base no resultado da ANOVA escreva as hipóteses e a conclusão

Chapter 5

Comparação de médias

5.1 Teste de Tukey

5.1.1 Aplicação no R studio

5.1.2 Exercicíos

5.2 Teste de Duncan

5.2.1 Aplicação no R studio

5.2.2 Exercicíos

5.3 Teste de Dunnett

5.3.1 Aplicação no R studio

5.3.2 Exercicíos

5.4 Teste de Scheffé

5.4.1 Aplicação no R studio

5.4.2 Exercicíos

5.5 Contrastes ortogonais

5.5.1 Aplicação no R studio

5.5.2 Exercicíos

Chapter 6

Regressão polinomial

6.1 Anova

6.2 Aplicação no R studio

6.3 Exercicíos

Chapter 7

Delineamento em blocos casualizados

7.1 Anova

7.2 Aplicação no R studio

7.3 Exercicíos

Chapter 8

Delineamento quadrado latino

8.1 Anova

8.2 Aplicação no R studio

8.3 Exercicíos

Chapter 9

Experimento fatorial

9.1 Anova

9.2 Aplicação no R studio

9.3 Exercicíos

Chapter 10

Experimento em parcelas subdivididas e em faixas

10.1 Anova

10.2 Aplicação no R studio

10.3 Exercicíos